

2. Information Measure

Vaughan Sohn

October 6, 2024

Entropy

Mutual Information

KL-Divergence

Remarks about Informations measures

Convexity and Concavity of Information Measures

Data Processing Inequality and Fano's Inequality

Entropy

Represent INFORMATION

어떤 사건 E 가 발생했을 때, 그 사건이 매우 *희귀하다*면 우리에게 많은 정보를 제공해주겠지만, 매우 흔한 사건이라면 별 다른 정보를 제공해주지 않을 것이다.
 \Rightarrow 이러한 직관에 기반하여, entropy를 다음과 같이 정의해보자.

Definition 1 (entropy on event)

For the event E , we define a measure of information, **entropy** $H(E) \in \mathbb{R}^+$ that satisfies the following properties:

- Function of $P(E)$
- Continuous in $P(E)$
- If $P(E)$ is increasing, then entropy $H(E)$ is decreasing
- If $E_1 \perp E_2$, then joint entropy is just addition of each entropy

$$H(E_1 \cap E_2) = H(E_1) + H(E_2)$$

Therefore, the entropy can be defined by the following function,

$$H(E) \triangleq -\log P(E)(\text{bits}).$$

일반화하면, 특정한 event E 가 아니라 random variable; experiment에 대한 entropy도 다음과 같이 정의할 수 있다.

⇒ **Average** amount of information by observing the realization of X . (i.e., $x \in \mathcal{X}$)

Definition 2 (entropy on random variable)

The entropy $H(X)$ of a discrete random variable X is defined by

$$H(X) = - \sum_{x \in \mathcal{X}} P_X(x) \log P_X(x)$$

By definition, entropy has following properties:

- $H(P) \geq 0$, with equality iff P is deterministic.
- $H(P)$ is continuous in $P \in \mathbb{R}^{|\mathcal{X}|}$
- H is *divisible* with successive choices

Example:

$$H([1/2, 1/3, 1/6]) = H([1/2, 1/2]) + \frac{1}{2}H([2/3, 1/3])$$

Examples:

- Binary random variable $X \sim \text{Bernoulli}(p)$ 인 r.v.에 대해 entropy를 구하라.

$$H_B(p) \triangleq$$

- Random variable uniformly distributed over a finite set r.v. U 에 대한 sample space가 $\mathcal{U} = \{1, 2, \dots, M\}$ 이고 uniform distribution을 따를때, entropy를 구하라.

$$H(U) \triangleq$$

Definition 3 (joint entropy)

The **joint entropy** $H(X, Y)$ of a pair of discrete random variables (X, Y) with a joint distribution $P_{X,Y}(x, y)$ is defined as

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} P_{X,Y}(x, y) \log P_{X,Y}(x, y)$$

Definition 4 (conditional entropy on observable)

The **conditional entropy** of Y , conditioned on $X = x$ is defined as

$$H(Y|X = x) = - \sum_{y \in \mathcal{Y}} P_{Y|X}(y|x) \log P_{Y|X}(y|x).$$

Definition 5 (conditional entropy on r.v.)

The **conditional entropy** of Y , conditioned on X is defined as

$$H(Y|X) = \mathbb{E}_{P_X}[H(Y|X = x)] = \mathbb{E}_{P_{XY}}[-\log P_{Y|X}(Y|X)]$$

✓ meaning: Random variable X 에 대한 entropy $H(X)$ 가 가능한 outcome $x \in \mathcal{X}$ 의 entropy $H(X = x)$ 의 **expectation**으로 정의되는 것처럼, random variable X 자체에 대한 conditioned entropy $H(Y|X)$ 는 X 가 가질 수 있는 모든 outcome $x \in \mathcal{X}$ 에 대한 **conditioned entropy** $H(Y|X = x)$ 의 **expectation**으로 정의할 수 있다.

* Proof: Joint probability에 대한 표현으로 전환하는 과정을 기술하면 다음과 같다.

⇒

Theorem 6 (chain rule)

$$\begin{aligned}H(X, Y) &= H(X) + H(Y|X) \\ &= H(Y) + H(X|Y)\end{aligned}$$

* Proof:

\Rightarrow

Examples

Example: 다음의 joint probability가 주어졌을 때, 각각의 entropy를 구하라.

	X = 0	X = 1
Y = 0	1/2	1/3
Y = 1	0	1/6

- $H(X), H(Y)$
- $H(X, Y)$
- $H(Y|x = 0), H(Y|x = 1)$
- $H(Y|X)$

⇒

Mutual Information

Definition 7 (mutual information)

The **mutual information** $I(X; Y)$ is defined as

$$I(X; Y) \triangleq H(X) - H(X|Y)$$

✓ meaning: $H(X)$ 가 X 에 대한 정보[*], $H(X|Y)$ 가 Y 를 알았을 때 X 에 대해 남아있는 정보이므로 $I(X; Y)$ 는 Y 를 알게됨으로서 얻은 X 에 대한 정보로 해석할 수 있다.

- Dependency on channel $W = P_{Y|X}$,
 - 채널이 완전하다면 $I(X; Y) = H(X) \leftrightarrow H(X|Y) = 0$
 - 채널이 불완전하여 손실되는 정보가 있다면 $I(X; Y) = 0 \leftrightarrow H(X|Y) = H(X)$
- By definition, mutual information has following properties:

- independence:

$$X \perp Y \rightarrow I(X; Y) = 0$$

- symmetry relation: (*)

$$I(X; Y) = H(Y) - H(Y|X) = H(X) - H(X|Y)$$

Definition 8 (conditional mutual information)

The **conditional mutual information** $I(X; Y|Z)$ is defined as

$$\begin{aligned} I(X; Y|Z) &\triangleq H(X|Z) - H(X|Y, Z) \\ &= H(Y|Z) - H(Y|X, Z) \end{aligned}$$

- Conditional mutual information을 정의하기 위해 conditioned r.v. Z 의 모든 realization에 대한 expectation을 취하여 계산할 수 있다.

$$I(X; Y|Z) = \mathbb{E}_Z[I(X; Y|Z = z)]$$

- 예를 들어, conditioned r.v. Z 는 channel을 이용한 transmission에서 어떤 channel을 사용할 지 결정하는 요소가 될 수 있다.

Theorem 9 (chain rule)

$$\begin{aligned} I(\underbrace{X_1, X_2}_{\text{joint r.v.}}; Y) &= I(X_1; Y) + I(X_2; Y|X_1) \\ &= I(X_2; Y) + I(X_1; Y|X_2) \end{aligned}$$

* Proof:

\Rightarrow

KL-Divergence

Definition 10 (KL-divergence)

The *relative entropy* or **Kullback-Leibler distance** between two PMF $P_X(x)$ and $Q_X(x)$ is defined as

$$D(P||Q) \triangleq \sum_{x \in \mathcal{X}} P_X(x) \log \frac{P_X(x)}{Q_X(x)} = \mathbb{E}_{P_X} \left[\log \frac{P(X)}{Q(X)} \right]$$

- KL divergence는 동일한 sample space에 대한 서로 다른 확률분포간의 차이; *distance*를 정량화한다.
- ||의 오른쪽에 위치한 PMF Q 는 분모에 위치하기 때문에, KL divergence가 잘 정의되기 위해서는 다음 조건을 만족해야한다.
 - P is dominated by Q ($P \ll Q$) [*]
 - If $Q(X) = 0$, then $P(X) = 0$ (for all $x \in \mathcal{X}$).

By definition, KL-Divergence has following properties:

- KL divergence is *not symmetric*

$$D(P||Q) \neq D(Q||P)$$

- when $P = Q$, then KL divergence is $D(P||Q) = 0$
- **information inequality**

Theorem 11 (information inequality)

KL divergence is non-negative

$$D(P||Q) \geq 0 \text{ with equality iff } P = Q.$$

* Proof:

Remarks about Informations measures

Theorem 12

$H(X) \leq H(U)$, where U is the uniform distribution over \mathcal{X} (equality iff U is uniformly distributed)

* Proof:

Theorem 13

$H(Y) \geq H(Y|X)$, with equality iff $X \perp Y$.

Theorem 14

$I(X; Y) \geq 0$, with equality iff $X \perp Y$.

* Proof:

Another definition of mutual information

KL-divergence를 사용하면 mutual information을 다른 관점으로 해석할 수 있다.

Definition 15 (mutual information)

Consider two random variables X and Y with a joint PMF $P_{X,Y}(x,y)$ and marginal PMF $P_X(x)$ and $P_Y(y)$. The **mutual information** $I(X;Y)$ is the relative entropy *between the joint distribution $P_{X,Y}(x,y)$ and the product distribution $P_X(x) \cdot P_Y(y)$.*


$$I(X;Y) \triangleq D(P_{X,Y}(x,y) || P_X(x)P_Y(y)) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} P_{X,Y}(x,y) \log \frac{P_{X,Y}(x,y)}{P_X(x)P_Y(y)}$$

* Proof: 첫 번째 정의와 두 번째 정의가 동일함을 보이자.

⇒

Application of Information Measures

- Entropy: Data compression (e.g, Huffman code)
- Mutual information: Data transmission



- KL divergence: Hypothesis testing [$*$]
 - 어떤 sample space에 대해서 서로 다른 두 hypothesis를 가정해 볼 수 있다.
 $H_0: X \sim P, H_1: X \sim Q$
 - X 를 여러번 관측하여 얻은 realization value를 사용하여 얻은 empirical distribution 으로부터 실제 probability distribution을 유추할 수 있기 때문에, 어떤 hypothesis가 진실인지 추정할 수 있다.
 - Hypothesis testing에서 추정이 틀렸을 확률은 다음과 같이 정의된다.

$$P(*) \approx \exp[-nD(P||Q)]$$

- 따라서 두 PMF의 KL divergence를 알고있다면 얼마나 많은 데이터(= n)가 있어야 우리가 원하는 수준의 error-rate를 달성할 수 있는지를 계산할 수 있다.

Convexity and Concavity of Information Measures

Definition 16 (convexity)

Definition 17 (concavity)



Lemma 18 (log-sum inequality)

* Proof:

Theorem 19

- ✓ meaning:

* Proof:

Corollary 20

✓ meaning:

* Proof:

Corollary 21

✓ meaning:

* Proof:

Corollary 22

✓ meaning:

* Proof:

Data Processing Inequality and Fano's Inequality

Definition 23 (Markov chain)

-

Theorem 24 (data processing inequality)

✓ meaning:

* Proof:

Corollary 25 (Data Processing Inequality on entropy)

Corollary 26 (Data Processing Inequality on KL-divergence)

System:

Theorem 27 (Fano's inequality)

✓ meaning:

* Proof:

Notations

- entropy of r.v. $X \sim P_X$: $H(X), H(P_X)$
- conditional entropy of Y conditioned on $X = x$: $H(Y|X = x), H(P_{Y|X}(\cdot|x))$
- conditional entropy of Y conditioned on X : $H(Y|X), H(P_{Y|X})$
- mutual information of X, Y : $I(X; Y), I(P_X \cdot P_{Y|X}), I(P_X, P_{Y|X})$
주로 $W = P_{Y|X}$ 로 두고 $I(P_X \cdot W)$ 와 같이 표기하여 사용한다.
- KL divergence between two distribution P and Q : $D(P||Q), D(P_P||P_Q)$

- T. M. Cover and J. A. Thomas. Elements of Information Theory, Wiley, 2nd ed., 2006.
- Lecture notes for EE623: Information Theory (Fall 2024)